张晓智

个人主页 ascendho 595 | 1.4k xiaozhizhang1207@163.com +86 166 6377 4856

教育背景

北京理工大学 · 珠海	计算机技术	硕士在读	2027.09 – 2030.06
河南大学 · 人工智能学院	人工智能	本科	2023.09 – 2027.06

专业技能

- 理解向量嵌入的底层原理，具备使用 Qdrant、Redis 等主流向量数据库构建高效检索系统的实操经验
- 深入理解 LLM Agent 架构与 RAG 检索技术，具备使用 LangChain 与 LangGraph 构建复杂的 Agent 工作流的经验
- 熟悉模型对齐微调流水线，了解 SFT 与 LoRA 技术，具备基于 GRPO 强化学习算法优化模型推理能力的实战经验
- **英语能力**：CET-6 **563** 分，具备适应英文工作环境的能力

项目经历

DistFlow 分布式任务调度与流处理引擎 *code* *demo*

- **技术栈**：Go、gRPC、etcd、Kafka、Redis、Docker
- **项目介绍**：面向大规模数据处理场景的分布式任务调度系统，重点解决节点负载不均、任务失败级联和状态一致性等问题。系统采用主从架构，Master 节点基于 etcd 实现服务发现与选举，通过一致性哈希将任务路由至 Worker 节点。每个 Worker 内部维护三级优先级队列（实时、批处理、延迟），结合背压机制动态调控消费速率，避免下游服务过载。任务执行过程中，系统通过 Checkpoint 机制定期快照中间状态，在节点故障时实现秒级恢复。此外，基于 Kafka 构建的事件溯源日志确保所有任务状态变更可审计、可回放。系统还提供 Web 控制台用于任务提交、进度监控和历史回溯，支持定时调度与依赖编排。
- **实验评估**：在 5 节点集群、10000 个模拟任务的压测中，系统吞吐量达到 3200 tasks/s，P99 调度延迟控制在 48ms 以内。相比单机串行方案，任务完成时间缩短 72%；节点故障恢复时间中位数为 2.3s，任务丢失率为 0%。

PanoSeg 全景视频实时语义分割管线 *code* *demo*

- **技术栈**：Python、PyTorch、ONNX Runtime、Triton Inference Server、OpenCV、CUDA
- **项目介绍**：聚焦全景视频在高分辨率下推理延迟过高、边缘设备资源受限等问题，构建端到端的实时语义分割管线。前端采用自适应分辨率缩放策略，根据场景复杂度动态调整输入尺寸，在精度与速度之间取得平衡。模型侧基于 MobileNetV3 骨干网络设计轻量分割头，并通过 ONNX 导出 + TensorRT 量化将模型体积压缩至 4.2MB，推理延迟降低 58%。部署层使用 Triton Inference Server 实现动态批处理与模型热更新，支持多版本模型并行服务与 A/B 测试。后端还实现了时序一致性后处理，利用相邻帧的语义连续性平滑预测结果，消除闪烁伪影，并通过 CUDA 流并行进一步压缩后处理开销。
- **实验评估**：在 Cityscapes 全景子集上，模型 mIoU 达到 72.8%，端到端推理延迟为 18.7ms/frame（RTX 3060），满足 50 FPS 实时处理需求。相比基线模型，FLOPs 减少 64%，内存占用降低 47%，在 Jetson Nano 边缘设备上仍可稳定运行。

KnowGraph 领域知识图谱构建与智能问答平台 *code*

- **技术栈**：Python、FastAPI、Neo4j、spaCy、Hugging Face Transformers、React
- **项目介绍**：针对垂直领域知识分散、检索效率低下的问题，设计并实现了一套从非结构化文本到可交互知识图谱的完整流水线。抽取阶段，通过实体识别（NER）与关系抽取（RE）联合模型从文档中提取三元组，并结合共指消解与实体对齐对抽取结果进行去重与融合，有效解决了同一实体的多名称指代问题。图谱构建阶段，将三元组写入 Neo4j 并建立全文索引，支持 Cypher 模板化查询与自然语言查询的双通道检索。前端基于 React 实现力导向图可视化，支持节点展开、路径高亮和子图导出。问答模块通过 Text-to-Cypher 将用户自然语言问题翻译为图查询语句，从图谱中检索答案并附带推理路径，支持多跳推理与聚合统计类查询。
- **实验评估**：在 200 篇领域论文构建的知识图谱上，实体抽取 F1 达到 85.3%，关系抽取 F1 达到 78.6%。问答模块在 50 道测试题上准确率为 82%，平均查询响应时间为 340ms，相比纯文本检索方案，答案召回率提升 31%。

科研成果

- **SCI 二区在投，学生一作**：物联网异常检测框架研究
- **IEEE 某国际会议，第二作者**：基于图神经网络的结构健康监测方法
- **IEEE Sensors Journal（SCI 二区），学生二作，Accepted**：跨设备数据完整性框架
- **一项发明专利**已受理；**一项软件著作权**已登记

奖项与证书

- **团队竞赛**：以团队第一的身份参加某省级大学生创新大赛（2025），并获得国家级二等奖
- **奖学金**：2024、2025 学年研究生三等学业奖学金；本科期间获院级二等、三等奖学金各一次
- **MOOC 认证**：自主学习大模型应用开发最新技术，并在 Coursera、Udemy、Harvard 等平台取得多项课程证书
- **ACM**：校内选拔赛二等奖（2026），并代表学校参加区域赛，获得优秀奖